

Лабораторная работа: Извлечение данных (PDF Parsing & OCR)

В этой работе мы сравним базовые методы парсинга с современными подходами (OCR и Intelligent Document Processing).

Задание 1: Базовый парсинг (pypdf)

Задача: Извлечь текст из **финансового отчета Казтелеком**, используя простую библиотеку `pypdf`.

- **Библиотека:** `pypdf` ([GitHub](#))
- **Документ:**

 kaztelecom.pdf 2.1 MiB

- **Страницы:** 11, 12
- **Формат ответа:** JSON

Дедлайн: 19:25

Пример структуры JSON:

JSON

```
{ "filename": "kaztelecom.pdf", "pages": [ { "page": 2, "text": "Текст со  
страницы..." }, { "page": 7, "text": "Текст со страницы..." } ] }
```

✂ Задание 2

Задача: Извлечь данные из того же **финансового отчета КазахТелекома**, но используя инструмент нового поколения — **Docling**.

Дедлайн: 19:45

- **Документ:** Казахтелекома
- **Страницы:** 11, 12, 16
- **Инструмент:** **Docling** (IBM)
- **Цель:** Посмотреть, как Docling справится со структурой документа (таблицами, заголовками) по сравнению с простым **pypdf** из первого задания.
- **Формат ответа:** JSON

✂ Задание 3

Задача: Извлечь текст из **отсканированной книги**, где обычное выделение текста не работает.

Дедлайн: 20:16

- **Документ:**

 G25 Central Asia reading (1)-1-4.pdf 5.6 MiB

- **Инструменты (выберите любой):**

- *Transformer Era*: **Surya OCR** или **PaddleOCR** (рекомендуется).
- *Deep Learning Era*: **EasyOCR**.
- Можно облачные!

- **Цель:** Получить читаемый текст из картинки.

Задание 4: Работа с VL-моделями (Текст + Графики)

Дедлайн: 20:36

Задача: Использовать мультимодальный подход для извлечения структурированных данных из всех графиков и диаграмм документа.

- **Документ:** `1 - mu-stat-grafiki_-2002-10-11.pdf` (все страницы документа).

- **Цель:** Превратить все графики и диаграммы из документа в структурированные JSON-массивы данных.
- **Инструменты:** Разрешается использовать API (GPT-5 Vision, Claude Vision, Gemini Vision) или Open Source VL-модели (LLaVA, Qwen-VL, и др.).
- **Формат ответа:** JSON с данными из каждого графика/диаграммы.

Пример структуры JSON:

```
{ "filename": "1 - mu-stat-grafiki_-2002-10-11.pdf", "charts": [ { "page": 1, "chart_title": "Название графика", "data": [ {"label": "2020", "value": 150}, {"label": "2021", "value": 175} ] } ] }
```