

Интеграция мультимодальности — задания

Модуль 6, семинар 4 · Персональный AI-агент с говорящим аватаром

Подготовка. Зарегистрируйтесь на `fal.ai` и получите API-ключ (`FAL_KEY`), подготовьте ключ OpenAI (`OPENAI_API_KEY`). Установите зависимости: `pip install fal-client openai python-dotenv`. Заранее запишите: аудио-вопрос (любой формат: m4a, mp3, wav), сэмпл своего голоса длительностью **не менее 10 секунд** и подготовьте своё фото (анфас, хорошее освещение, один человек в кадре).

1 Speech-to-Text: аудио-вопрос → текст

Напишите Python-скрипт, который принимает файл с записанным аудио-вопросом и возвращает его текстовую расшифровку.

ВХОД

`python3 task1.py question.m4a`

ВЫХОД

распознанный текст вопроса в консоли

- Загрузите файл в хранилище fal: `fal_client.upload_file(...)`
- Распознайте речь моделью `fal-ai/whisper` (`task: "transcribe"`)

2 Ответ клонированным голосом

Напишите скрипт, который принимает аудио-вопрос и генерирует **звуковой ответ вашим клонированным голосом**.

ВХОД

аудио-вопрос + сэмпл вашего голоса (≥ 10 сек)

ВЫХОД

`answer.mp3` — ответ, озвученный вашим голосом

- Распознайте вопрос (шаг из задания 1)
- Сгенерируйте короткий ответ через LLM (например, `gpt-4o-mini`); попросите модель отвечать 2–3 предложениями — ответ будет озвучиваться
- Клонируйте голос: `fal-ai/minimax/voice-clone` → `custom_voice_id`
- Озвучьте ответ: `fal-ai/minimax/speech-02-hd`, передав свой `voice_id` в `voice_setting`
- Сохраните `voice_id` в файл и переиспользуйте при повторных запусках — клонирование платное

3 Видео-ответ вашего AI-клона

Напишите скрипт полного пайплайна: принимает аудио-вопрос и генерирует **видео «говорящей головы»** — ваш цифровой клон произносит ответ вашим клонированным голосом. Аудио и видео — вместе, **одним файлом**.

ВХОД

аудио-вопрос + сэмпл голоса + ваше фото

ВЫХОД

answer_video.mp4 — единый файл видео со звуком

- Соберите цепочку: ASR → LLM → TTS клонированным голосом (задания 1–2)
- Сгенерируйте видео: `fal-ai/kling-video/ai-avatar/v2/standard`, на вход — URL фото и URL аудио-ответа
- Модель возвращает mp4 уже со звуковой дорожкой — отдельно склеивать не нужно
- Учтите: генерация занимает несколько минут и стоит заметно дороже остальных шагов — отлаживайте шаги 1–2 отдельно, видео запускайте один раз

Справочник моделей

Этап	Модель
ASR (речь → текст)	<code>fal-ai/whisper</code>
LLM (генерация ответа)	<code>gpt-4o-mini</code> / Gemini Flash
Клонирование голоса	<code>fal-ai/minimax/voice-clone</code>
TTS (текст → речь)	<code>fal-ai/minimax/speech-02-hd</code>
Видео-аватар	<code>fal-ai/kling-video/ai-avatar/v2/standard</code>

Формат сдачи

- Три скрипта: `task1.py`, `task2.py`, `task3.py` (ключи — только через `.env`, не коммитьте их в код)
- Результаты: расшифровка вопроса, `answer.mp3`, `answer_video.mp4`